

Projet Outils Numériques – Big Data

Groupe 4 – Leportier Eliott, Beaussier Mélissa, Prétot Cécilia

Table des matières

Introduction	2
Fonctionnalité 1 : Analyse de données	2
Description des données.....	2
Nettoyage des données.....	3
Valeurs manquantes.....	3
Valeurs aberrantes	4
Statistiques univariées sur les données	5
Variables quantitatives	5
Variables qualitatives.....	5
Fonctionnalité 2 : Graphiques	6
Répartition des bateaux par leur type	6
Répartition des bateaux par leur catégorie	6
Top 10 des ports les plus fréquentés (trié par ordre décroissant).....	7
Répartition des vitesses des bateaux.....	7
Fonctionnalité 3 : Cartographie	8
Fonctionnalité 4 : Etude des corrélations	10
Corrélation entre variable Quantitatives/Quantitatives	10
Corrélation entre variables quantitatives et qualitatives.....	11
Corrélation entre variables qualitatives et qualitatives.....	11
Fonctionnalité 5 : Prédiction.....	12
Prédiction du type de navire.....	12
Prédiction de la vitesse.....	12
Annexe	13
Annexe 1 Annexe 2	13
Annexe 3 Annexe 4.....	13
Annexe 5	14
Annexe 6	14

Introduction

Les 3 semaines de projet Outils Numérique réalisées en A3 sur la Big Data, l'Intelligence Artificielle et le WEB ont pour but de nous faire approfondir les connaissances et méthodes vues en cours au cours du semestre 6. La semaine de Big Data explore principalement le traitement de données massives sur le logiciel R. Le projet consiste à exploiter un ensemble de données réelles issues du système d'identification automatiques des navires dans le golfe du Mexique (AIS).

Le projet de Big Data intègre des fonctionnalités d'exploration et nettoyage des données, visualisations graphiques et cartographiques, étude de corrélation et modélisation prédictive. Chaque section du rapport sera accompagnée de figures et d'interprétations afin de mettre en évidence les apports concrets des traitements que nous avons réalisés tout au long de la semaine.

Fonctionnalité 1 : Analyse de données

Avant de procéder à l'analyse avancée, il est essentiel de bien comprendre la structure et le contenu de notre jeu de données. Cette étape d'exploration nous a permis de décrire les variables disponibles, de réaliser différentes statistiques sur le jeu, d'identifier les valeurs manquantes, aberrantes ou dupliquées, et d'appliquer un premier nettoyage afin d'assurer la fiabilité des analyses futures.

Description des données

Après quelques recherches sur internet, il a été possible de décrire chaque colonne du jeu de données, et ainsi en déduire si chaque variable est considérée comme quantitative ou qualitative :

- ❖ **ID** : à voir comme qualitatif
- ❖ **MMSI** : (Maritime Mobile Service Identity) C'est un code à 9 chiffres unique attribué à un bateau ayant des équipements radio à bord. Pour un navire, les 3 premiers numéros renvoient au MID soit le Maritime Identification Digit en anglais. Ils indiquent sous quel pavillon l'équipement est enregistré. Ainsi, le premier chiffre déclare dans quelle région du monde se situe le bateau. En Europe, on nous attribue le 2. A voir comme qualitatif.
- ❖ **BaseDateTime** : Date liée au point récupéré du bateau. Quantitative.
- ❖ **LAT** : latitude d'un bateau. Quantitative.
- ❖ **LONG** : longitude d'un bateau. Quantitative.
- ❖ **SOG** : (Speed Over Ground) vitesse au sol. La vitesse du bateau par rapport à un point fixe. Elle peut être différente de la vitesse sur l'eau à cause des courants. Quantitative.
- ❖ **COG** : (Course over Ground). Route par rapport au sol. Peut être différente du cap à cause des courants et de la dérive du bateau. Quantitative.
- ❖ **Heading** : Il correspond à la distance verticale entre la flottaison et le point le plus bas de la coque, généralement la quille. Quantitative.
- ❖ **VesselName** : Nom du navire. Qualitatif.

- ❖ **IMO** : L'Organisation maritime internationale (OMI) a mis en place un système de numéros d'identification des navires en 1987 dans le but de prévenir la fraude maritime et d'améliorer la sécurité des navires marchands. A voir comme qualitatif.
- ❖ **CallSign** : Ensemble de lettres, code décrivant les actions et situations des navires à un moments donnée. Qualitatif.
- ❖ **VesselType** : Type de navire, reconnu par un numéro. Qualitatif et peut être associé à un mot grâce à d'autres fichiers d'identification.
- ❖ **Status** : Qualitative.
- ❖ **Length** : longueur du navire. Quantitatif. Potentielle variance à calculer
- ❖ **Width** : largeur du navire. Quantitatif. Potentielle variance à calculer
- ❖ **Draft** : Tirant d'eau → la hauteur de la partie immergée du bateau qui varie en fonction de la charge transportée. Quantitatif. Sa variabilité dans le temps est très utile pour savoir si le bateau est chargé
- ❖ **TransceiverClass** : Les transpondeurs AIS. L'AIS pour *Automatic Identification System* (en français : système automatique d'identification SIA) est un système mondial d'échange automatique de messages standardisés entre bateaux à partir d'émetteurs-récepteurs de signaux radio et GPS. L'AIS à bord transmet automatiquement l'identité de votre bateau (votre numéro MMSI), le nom de votre bateau, votre position GPS, votre cap et votre vitesse, ainsi que d'autres informations utiles. C'est un type de transpondeurs reconnus par une lettre. Qualitatif.

Nettoyage des données

Lors de cette étape nous devons modifier et préparer les données pour pouvoir les utiliser correctement. Le but est d'enlever les imperfections telle que les valeurs manquantes, les aberrations et les doublons tout en gardant le plus de données d'origine. Il existe différentes méthodes pour nettoyer des données. Ici, nous vous en présenterons une que nous avons choisie.

id	MMSI	BaseDateTime	LAT	LON	SOG	COG	Heading	VesselName	IMO	CallSign	VesselType	Status	Length	Width
<dbl>	<dbl>	<dtm>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<chr>	<chr>	<chr>	<dbl>	<chr>	<chr>	<chr>
82	6.36e8	2023-05-29 00:00:06	29.1	-89.3	13.4	228.	227	STOLT LOT...	"IMO..."	D5MX5	80	"0"	183	28
84	3.67e8	2023-05-29 00:00:01	25.8	-80.1	5.6	176	511	ISLAND QU...	"\\N"	WDE6981	60	"\\N"	20	7
91	3.67e8	2023-05-29 00:00:06	29.3	-90.0	0	267.	511	HERO	"IMO..."	WDH2114	60	"0"	47	9
103	3.67e8	2023-05-29 00:00:06	29.9	-90.0	0.4	269	511	FRANK H	"\\N"	WDC5212	60	"0"	15	5
118	3.68e8	2023-05-29 00:00:10	29.8	-92.2	7.1	51.4	511	ADRI LAB	"IMO..."	WDF2836	60	"15"	49	9
119	3.67e8	2023-05-29 00:00:10	27.8	-82.6	0	265.	294	PROVINCET...	"IMO..."	WDB8185	60	"0"	30	9

i 3 more variables: Draft <chr>, Cargo <chr>, TransceiverClass <chr>

Figure 1: Premières valeurs des données vessel_total_clean.csv

Valeurs manquantes

Dans un premier temps nous avons remplacé tous les "\\N" (valeurs manquantes) en "NA" pour ensuite enlever plus facilement ces valeurs. Il faudra bien faire la différence entre les colonnes de type caractère ou numérique. Si la colonne est numérique, il faudra la convertir en caractère pour pouvoir effectuer le changement.

id	MMSI	BaseDateTime	LAT	LON	SOG	COG	Heading	VesselName	IMO	CallSign	VesselType	Status	Length	Width
<dbl>	<dbl>	<dtm>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<chr>	<chr>	<chr>	<dbl>	<chr>	<dbl>	<chr>
82	6.36e8	2023-05-29 00:00:06	29.1	-89.3	13.4	228.	227	STOLT LOT...	IMO9...	D5MX5	80	0	183	28
84	3.67e8	2023-05-29 00:00:01	25.8	-80.1	5.6	176	511	ISLAND QU...	NA	WDE6981	60	NA	20	7
91	3.67e8	2023-05-29 00:00:06	29.3	-90.0	0	267.	511	HERO	IMO8...	WDH2114	60	0	47	9
103	3.67e8	2023-05-29 00:00:06	29.9	-90.0	0.4	269	511	FRANK H	NA	WDC5212	60	0	15	5
118	3.68e8	2023-05-29 00:00:10	29.8	-92.2	7.1	51.4	511	ADRI LAB	IMO8...	WDF2836	60	15	49	9
119	3.67e8	2023-05-29 00:00:10	27.8	-82.6	0	265.	294	PROVINCET...	IMO9...	WDB8185	60	0	30	9

i 3 more variables: Draft <chr>, Cargo <chr>, TransceiverClass <chr>

Figure 2: \N changer en NA

Ensuite, on doit enlever ou changer les NA en fonction de leur pourcentage de présence. Pour que le nettoyage se fasse correctement, il faut vérifier que toute la colonne soit au bon type. Par exemple, la largeur, la longueur et le tirant d'eau du bateau sont en caractère, alors que ce sont des valeurs numériques. Il faut donc convertir ces colonnes en numérique pour les futurs calculs puisse correctement s'effectuer. Même chose que pour les \N, il faut décomposer le changement pour les colonnes de caractère et numérique. Pour les valeurs numériques, nous avons calculé le pourcentage de NA dans la colonne. Si celui-ci est inférieur à 5%, alors nous supprimons la ligne concernée. Sinon, nous calculons le pourcentage d'aberrations et si celui-ci est inférieur à 5%, les NA sont remplacées par la moyenne. Sinon, l'aberration sera trop présente et impactera la moyenne, alors nous remplaçons les valeurs manquantes par la médiane de la colonne. En ce qui concerne les colonnes de type caractère, nous remplaçons simplement les valeurs manquantes par "INCONNUE".

id	MMSI	BaseDateTime	LAT	LON	SOG	COG	Heading	VesselName	IMO	CallSign	VesselType	Status	Length	Width
<dbl>	<dbl>	<dtm>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<chr>	<chr>	<chr>	<dbl>	<chr>	<dbl>	<dbl>
82	6.36e8	2023-05-29 00:00:06	29.1	-89.3	13.4	228.	227	STOLT LOT...	IMO9...	D5MX5	80	0	183	28
91	3.67e8	2023-05-29 00:00:06	29.3	-90.0	0	267.	511	HERO	IMO8...	WDH2114	60	0	47	9
103	3.67e8	2023-05-29 00:00:06	29.9	-90.0	0.4	269	511	FRANK H	INCO...	WDC5212	60	0	15	5
118	3.68e8	2023-05-29 00:00:10	29.8	-92.2	7.1	51.4	511	ADRI LAB	IMO8...	WDF2836	60	15	49	9
119	3.67e8	2023-05-29 00:00:10	27.8	-82.6	0	265.	294	PROVINCET...	IMO9...	WDB8185	60	0	30	9
139	3.67e8	2023-05-29 00:00:00	29.3	-94.8	11.3	333.	511	RAY STOKE...	IMO9...	WDJ3395	60	0	80	19

3 more variables: Draft <dbl>, Cargo <chr>, TransceiverClass <chr>

Figure 3: suppression ou changement des valeurs manquantes

Valeurs aberrantes

Dans cette partie nous gardons le même principe que la précédente pour remplacer les valeurs aberrantes. En utilisant la méthode des interquartiles pour déterminer les aberrations, puis on peut calculer le pourcentage. Si les valeurs aberrantes sont en dessous de 5% de présence, on remplace les NA par la moyenne. Sinon on ne les remplace pas la médiane.

id	MMSI	BaseDateTime	LAT	LON	SOG	COG	Heading	VesselName	IMO	CallSign	VesselType	Status	Length	Width
<dbl>	<dbl>	<dtm>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<chr>	<chr>	<chr>	<dbl>	<chr>	<dbl>	<dbl>
82	6.36e8	2023-05-29 00:00:06	29.1	-89.3	13.4	228.	227	STOLT LOT...	IMO9...	D5MX5	80	0	183	28
91	3.67e8	2023-05-29 00:00:06	29.3	-90.0	0	267.	511	HERO	IMO8...	WDH2114	60	0	47	9
103	3.67e8	2023-05-29 00:00:06	29.9	-90.0	0.4	269	511	FRANK H	INCO...	WDC5212	60	0	15	5
118	3.68e8	2023-05-29 00:00:10	29.8	-92.2	7.1	51.4	511	ADRI LAB	IMO8...	WDF2836	60	15	49	9
119	3.67e8	2023-05-29 00:00:10	27.8	-82.6	0	265.	294	PROVINCET...	IMO9...	WDB8185	60	0	30	9
139	3.67e8	2023-05-29 00:00:00	29.3	-94.8	11.3	333.	511	RAY STOKE...	IMO9...	WDJ3395	60	0	80	19

3 more variables: Draft <dbl>, Cargo <chr>, TransceiverClass <chr>

Doublons

On enlève simplement les doublons avec la fonction unique(). On remarque qu'il n'y a pas de doublons car aucune ligne n'est supprimée.

Après traitement, 5,5% des données ont été supprimées, ce qui est parfaitement raisonnable avec autant de données.

Statistiques univariées sur les données

Grâce à la fonction `summary()` de R, il est très simple d'observer les statistiques de bases des variables quantitatives (min, max, 1^{er} quartile, médiane, moyenne, 3^{ème} quartile). En voici un exemple :

```
VesselType      Status
Min.   :60.00   Min.    : 0.000
1st Qu.:60.00   1st Qu.: 0.000
Median :70.00   Median : 0.000
Mean   :68.58   Mean    : 2.885
3rd Qu.:80.00   3rd Qu.: 5.000
Max.   :89.00   Max.    :15.000
```

Comme on peut le voir, certaines colonnes ont mal été interprétée par le logiciel. `VesselType` possède des statistiques calculées comme s'il était une variable quantitative, or c'est faux.

Variables quantitatives

On peut calculer la variance, et récupérer les statistiques pour les variables que l'on a identifiées comme quantitative auparavant.

	BaseDateTime	LATITUDE	LONGITUDE	SOG	COG	Heading	Length	Width	Draft
minimum	2023-05-25 00:00:00.00	23,39	-97,38	0	0	0	0	0	0
1 quartile	2023-05-27 00:15:24.00	27,94	-94,35	0	126	124	39	9	5,8
median	2023-05-29 01:05:54.00	29,28	-90,2	0	228,2	297	87	20	7,588
mean	2023-05-28 11:51:59.910	28,71	-89,89	2,771	210,2	297,4	118,4	21,35	7,489
3rd quartile	2023-05-29 22:21:64.15	29,72	-88,99	2,771	300,5	511	185	32	9,8
maximum	2023-05-31 23:59:59.00	36,69	-75	17	360	511	334	60	16,3
variance		2,21185	26,64913	22,8078	11931,7586	32431,14724	8930,43617	180,39939	12,61512

Figure 4: Tableau de statistiques des variables quantitatives

Variables qualitatives

Concernant les variables qualitatives, étant donné qu'elles dérivent quelque chose, nous avons décidé de compter le nombre de modalités présentes pour chaque variable, et dans le cas où le nombre de modalités est inférieur à 30, de les afficher afin de les visualiser.

```
> # Nombre de modalités uniques
> sapply(vessel_total_clean[, qual_vars], function(x) length(unique(x)))
      id      MMSI      vesselName      IMO      callsign      vesselType
396878     141         141         118         141           11
Status
7
Cargo TransceiverClass
24      1
> #-> je vois que ça vaut le coup d'afficher celles de VesselType, Status, Cargo et TransceiverClass
```

VesselType	60	61	63	70	71	74	79	80	82	84	89
Passenger, all ships of this type	Passenger, hazardous category A	Passenger, no additional information	Cargo, all ships of this type	Cargo, hazardous category A	Cargo, hazardous category D	Cargo, no additional information	Tanker, all ships of this type	Tanker, hazardous category B	Tanker, hazardous category D	Tanker, no additional information	
	170544	1840	5517	100854	7766	2407	5544	91598	2511	1432	6805
Status	0	1	2	3	5	8	15				
	233781	45109	30	4616	48828	17980	46534				
Cargo	0	5	30	31	40	49	50	60	67	69	70
	3961	4646	8160	4916	4898	2986	14752	93114	3413	12799	89144
	74	77	79	80	81	82	83	84	85	89	90
	4693	1859	9396	72523	2346	8449	1766	1432	1912	13812	8430
TransceiverClass	A										
	396878										


Figure 5 5 : Nombre de variables par modalités (si modalités < 30) pour les variables qualitatives

Fonctionnalité 2 : Graphiques

La visualisation graphique est un outil fondamental pour résumer et interpréter rapidement de grands volumes de données. Nous avons utilisé des représentations telles que des histogrammes, des camemberts et des barplots pour mettre en évidence la répartition des types et catégories de navires, les ports les plus fréquentés ou encore leur vitesse.

Répartition des bateaux par leur type

Dans un premier temps, nous avons souhaité observer la répartition des bateaux selon leur type (VesselType) à l'aide d'un diagramme à barres, aussi appelé Barplot. Ce graphique permet de compter le nombre de navires pour chaque type. Cela nous permet d'identifier les types de bateaux les plus présents dans la base de données.



Après avoir affiché le graphique, nous avons remarqué que la variable VesselType est codée numériquement et chaque valeur représente un type précis de bateau. Nous observons qu'il y a principalement trois grands types :

- **Type 60** : environ 175 000 navires
- **Type 70** : environ 100 000 navires
- **Type 80** : environ 90 000 navires


Les autres types de bateaux sont moins fréquents, avec chacun moins de 10 000 occurrences.

Ce graphique met en évidence la variété de types de bateaux qui existe mais aussi une grande hétérogénéité dans la répartition des types de navires dans la base de données.

Répartition des bateaux par leur catégorie

Dans un deuxième temps, nous avons observé la répartition des bateaux selon leur catégorie. En effet, les types sont regroupés dans des catégories :

Nous avons donc choisi de représenter les catégories dans un camembert selon le pourcentage de chaque catégorie de navires.



Après l'affichage du graphique, on observe qu'il y a 3 grandes catégories de navires Cargo, Tanker, Passenger. On remarque qu'il n'y a pas de catégorie « Autres ». Cela s'explique par le fait que cette catégorie correspondait aux lignes avec des valeurs manquante (Na) dans la variable VesselType, et ces lignes ont été supprimées lors du nettoyage des données, ce qui a donc entraîné la disparition de la catégorie "Autre".

De plus, on observe que la majeure partie des navires sont des « Passenger », il y a donc une forte présence de


bateaux à passagers tel que des Ferries ou des navettes maritimes. Ensuite, il y a la catégorie « Cargo » qui transportent la marchandise et les « Tanker » qui regroupent les navires citernes.

Cette visualisation met en évidence un déséquilibre dans la répartition des catégories de bateaux.

Top 10 des ports les plus fréquentés (trié par ordre décroissant)

Dans un troisième temps, nous avons identifié les ports les plus fréquentés. Pour cela, nous avons d'abord calculés les positions AIS, c'est-à-dire le croisement entre latitude et longitude où les bateaux se trouvaient le plus souvent.


```
ports <- data.frame(
  Latitude = c(29.3, 29.1, 29.7, 29.9, 26.1, 29.8, 29.7, 27.8, 30.0, 29.6),
  Longitude = c(-89.4, -90.2, -91.1, -90.1, -80.1, -93.3, -95.3, -97.1, -90.1, -89.9),
  Nom = c("Port of Venice", "Port of Fourchon", "Port of Morgan City", "Port of Marrero/New Orleans",
    "Port Everglades", "Port of Cameron", "Port of Houston", "Port Aransas/Corpus Christi",
    "Port of New Orleans", "Zone Delta Mississippi")
)
```



Nous en avons alors tiré 10 coordonnées qui, après quelques recherches se sont avérées être des ports dans le golfe du Mexique. Ensuite nous avons stockés toutes les coordonnées dans un data frame ainsi que le nom du port correspondant. Pour afficher ce barplot, nous avons considéré qu'un navire se trouve à « proximité » d'un port s'il se situe dans un rayon d'environ 0.1 degré, soit environ 10 km autour de ses coordonnées GPS. Nous avons ensuite classé ces ports par ordre décroissant de fréquentation. On observe ainsi que des ports comme le Port of Venice ou le Port of Fourchon sont les plus fréquentés. Ce graphique nous a permis d'avoir une vision globale des principaux ports présents dans la base de données.

Répartition des vitesses des bateaux

Dans cette dernière partie nous avons souhaité analyser la variable SOG (Speed Over Ground) qui représente la vitesse des bateaux. Pour ceci, nous avons réalisé un histogramme qui nous a permis de regrouper les vitesses par intervalles ainsi que de compter combien de navires se trouvent dans chaque tranche.



D'après le graphique, on constate que la majorité des bateaux se déplacent à des vitesses comprises entre 0 et 15 nœuds, avec un large pic à 0. Cela signifie que la plus grande partie des bateaux est à l'arrêt ou quasi-immobile, ce qui correspond à des navires en attente, à quai dans un port ou ancrés. Ce graphique nous permet donc de comprendre la dynamique des navires et donne une vision globale des vitesses maritimes dans la base de données.

Fonctionnalité 3 : Cartographie

Grâce aux coordonnées GPS fournies dans les données AIS, nous avons pu tracer les trajectoires des navires sur une carte. Cette représentation géographique offre une meilleure compréhension des routes maritimes empruntées, et permet de détecter des motifs de navigation spécifiques selon le type de navire ou son état de chargement.

Dans notre cas, les trajectoires des navires ont été réalisées grâce à la librairie Leaflet. En passant la souris sur une ligne, on affiche certaines informations essentielles sur le bateau telles que son MMSI, son nom et son type (en toute lettres grâce au tableau de correspondance). La date et l'heure de chaque point ont voulu être ajoutées mais malheureusement, cela impliquait trop de données à charger sur la carte et nos ordinateurs n'étaient pas assez puissant pour cela.

Pour continuer, en réglant l'opacité des lignes de trajectoire des bateaux sur un niveau très faible (0.1), les lignes de trajectoires vont se superposer lorsqu'elles passent au même endroit. Ainsi, les lignes qui apparaissent le plus rouge possible sont les routes les plus empruntées par les bateaux. Ses routes sont déjà connues sur internet, parmi elles on retrouve les corridors Houston–Gul, Western Gulf Shipping Routes ou Straits of Florida shipping lanes.




Figure 36: Carte des trajectoires dans le Golfe du Mexique




Figure 47: Carte des routes les plus empruntées par les bateaux dans le Golfe du Mexique

Par la suite, les dessins de trajectoires ont été modifiées pour être représentées par des lignes de couleurs en fonction du type du bateau, avec la légende en bas à droite de la carte. Ceci a été réalisé grâce à la fonction ColorFactor principalement.




Figure 58: Carte des trajectoires colorées selon le type de bateau, dans le Golfe du Mexique

Et enfin, nous avons réalisé une légende interactive pour cocher/décocher l'affichage des types de bateau. Cela a été réalisé grâce à des couches de calques, avec la fonction `addLayersControl()`.




Figure 69: Carte avec version 1 des couches de calques dans le Golfe du Mexique




Figure 6bis: Carte avec version 2 des couches de calques dans le Golfe du Mexique

Pour terminer, nous avons ajouté les départs et « arrivées » des bateaux grâce à la fonction `addCircleMarkers()`. En effet, au début du projet, nous avons essayé d'ajouter des markers à chaque points (420000). Cela était beaucoup trop lourd à supporter pour l'ordinateur. Ici, il n'y a que 300 markers, ce qui est supportable pour l'ordinateur.




Figure 10: Carte finale composée des trajectoires par type de bateau, des départs et arrivées de chaque trajet, et des couches de calques pour afficher ou non les types de bateau

Fonctionnalité 4 : Etude des corrélations

L'objectif de cette fonctionnalité est de comprendre les relations entre les variables. Cette étape est cruciale pour identifier les facteurs influents. Elle consiste à analyser les dépendances entre variables, qualitatives ou quantitatives, à travers des analyses bivariées, des tableaux croisés, des tests d'indépendance du Khi2 et des visualisations adaptées (régressions linéaires simples, mosaïques, boîtes à moustaches).

Nous avons mené des analyses bivariées entre variables quantitatives/quantitatives, quantitatives/qualitatives et qualitatives/qualitatives.

Corrélation entre variable Quantitatives/Quantitatives

Afin d'étudier les liens entre deux variables quantitatives, nous avons utilisé le coefficient de corrélation de Pearson, qui permet de mesurer l'intensité et le sens de la relation entre deux variables.

L'ensemble de ces coefficients de corrélation a été rassemblé dans une matrice de corrélation ([voir Annexe 1](#)). Cette matrice permet de visualiser les relations numériques entre toutes les variables quantitatives de notre jeu de données. On distingue trois types de corrélations possibles : positive ($r > 0$), négative ($r < 0$) ou inexistante ($r = 0$). Plus la valeur de r est proche de 1 (ou de -1), plus la corrélation est forte.

D'après la matrice de corrélation ([voir Annexe 1](#)), plusieurs corrélations ressortent comme significatives :

- *Length et Width* : $r = 0.88$ (corrélation positive significative)
- *Width et Draft* : $r = 0.60$ (corrélation positive modérée)
- *Length et Draft* : $r = 0.62$ (corrélation positive modérée)
- *Heading et Length* : $r = -0.65$ (corrélation négative significative)
- *Heading et Width* : $r = -0.56$ (corrélation négative modérée)

Les autres coefficients étant trop proches de zéro, ils n'ont pas été jugés suffisamment significatifs dans le cadre de cette étude. Pour illustrer ces trois types de relations, nous avons réalisé des régressions linéaires sur trois couples de variables représentatifs :


Corrélation positive : comme on peut le voir dans l'[Annexe 2](#), il y a une corrélation positive entre Length et Width, car la droite de régression présente une pente ascendante, ce qui est cohérent avec la corrélation positive obtenue précédemment.

Corrélation négative : Dans l'[Annexe 3](#), la droite de régression entre Heading et Length montre une pente descendante, ce qui confirme la corrélation négative observée dans la matrice.

Absence de corrélation : l'[Annexe 4](#) montre une droite quasi horizontale entre Draft et LAT, ce qui traduit une absence de corrélation linéaire entre ces deux variables.

Corrélation entre variables quantitatives et qualitatives

Afin d'étudier le lien entre une variable quantitative et une variable qualitative, nous avons fait des boîtes à moustaches puis un test ANOVA. Nous avons pris comme exemple le lien entre la longueur des navires (Length) et leur type (VesselType).



Le graphique montre clairement que la longueur varie fortement selon le type de navire. En effet, les types 70, 74, 84 et 89 présentent des longueurs élevées avec des médianes proches ou supérieures à 200 mètres. À l'inverse, les types 60, 61 et 69 ont des longueurs nettement inférieures (< 50 mètres). On observe aussi une grande dispersion pour certains types (70, 79 et 89), ce qui traduit une diversité importante au sein de ces catégories.

Pour vérifier si ces différences sont statistiquement significatives, nous avons réalisé une ANOVA.


	Df	Sum Sq	Mean Sq	F value	Pr(>F)
as.factor(VesselType)	10	1394965	139497	15328	$<2e-16$ ***
Residuals	396867	3611686	9		

On remarque que $p\text{-value} < 2e-16$, les différences de longueur entre les types de navires sont hautement significatives ce qui signifie que le type de navire a une influence directe sur sa longueur.

Corrélation entre variables qualitatives et qualitatives

Pour étudier la relation entre les deux variables qualitatives, nous avons réalisé un test d'indépendance du χ^2 ainsi qu'une visualisation à l'aide d'un mosaicplot. Pour cette étude, nous avons travaillé avec les variables VesselType (type de navire) et Status (statut du navire).

Le test du χ^2 nous a permis d'obtenir une $p\text{-value}$ inférieure à $2.2e-16$, ce qui indique une dépendance statistiquement significative entre les deux variables. Autrement dit, le type de navire et son statut ne sont pas indépendants. Il existe donc une corrélation entre ces deux variables.



Le mosaicplot permet de visualiser la répartition croisée des modalités des variables. On observe que le statut 0 (en bleu clair) est largement dominant dans l'ensemble des données, notamment pour les types de navires 30, 70 et 80, où il représente presque la totalité des effectifs. Les statuts 5 et 15 sont moins présents, principalement pour les types 60, 70 et 80. D'autres types, tels que 32, 52, 71, 74 et 89, présentent une répartition plus diversifiée entre les différents statuts.

Il existe donc une forte dépendance entre le type de navire et son statut. En effet, certains types de navires sont plus spécialisés et effectuent donc souvent les mêmes types de missions, ce qui les associe plus fréquemment à un statut particulier. Par exemple, un navire de type Passenger, destiné au transport de passagers passe la majorité de son temps en navigation. Cela explique pourquoi il est majoritairement associé au statut 0, qui correspond à un navire en route.

Fonctionnalité 5 : Prédiction

L'objectif final de notre étude était de construire un modèle prédictif capable d'estimer le type de navire à partir des autres variables disponibles. Pour cela, nous avons utilisé des techniques de régression logistique et évalué les performances de nos modèles en mesurant l'erreur de classification sur un échantillon de test.

Prédiction du type de navire

La première prédiction porte sur la variable VesselType, qui indique la catégorie du navire. Pour cela, nous avons sélectionné les variables qui sont liées à VesselType comme la vitesse (SOG), le cap vrai (COG), l'orientation du navire (Heading), la longueur (Length), la largeur (Width), le tirant d'eau (Draft) et le type de cargaison (Cargo). Avant d'appliquer le modèle, nous avons transformé la variable VesselType en facteur, car il s'agit d'une variable catégorielle. Ensuite, nous avons utilisé une régression logistique multinomiale, avec la fonction `multinom()` du package *nnet*. Une fois le modèle entraîné, nous avons généré des prédictions sur notre jeu de données. Pour évaluer les performances du modèle, nous avons utilisé une matrice de confusion qui nous permet de voir quelles classes ont été correctement ou incorrectement prédites. Enfin, un graphique en barres a été ajouté pour visualiser la répartition des classes prédites par rapport aux classes réelles (voir Annexe 5).

Prédiction de la vitesse


La deuxième prédiction porte sur la vitesse réelle du navire (SOG). Pour cela, nous avons sélectionné les variables Length, Width, Draft et Cargo. Nous avons ensuite utilisé un modèle de régression linéaire, avec la fonction `lm()`, afin de prédire la vitesse en fonction de ces caractéristiques.

Une fois les vitesses prédites obtenues, nous avons calculé l'erreur de notre modèle en utilisant la racine de l'erreur quadratique moyenne (RMSE). Cela nous donne une estimation de l'erreur moyenne entre la vitesse réelle et la vitesse prédite.


Nous avons aussi tracé un graphique en nuage de points comparant les vitesses réelles et les vitesses prédites. Une ligne rouge représentant l'égalité parfaite ($SOG_{réel} = SOG_{prédit}$) a été ajoutée pour observer à quel point les prédictions s'en approchent. On peut remarquer sur le graphe en Annexe 6 que la grandeur de l'échantillon étudié rend illisible le graphique.

Annexe


Annexe 1




Annexe 2



Annexe 3



Annexe 4



Annexe 5




Figure 11: Comparaison des classes réelles vs classes prédites

Annexe 6




Figure 12: Comparaison entre les vitesses réelles et les vitesses prédites